



共享电动自行车路段超速 风险影响因素分析

张晓龙¹ 边 扬¹ 赵晓华¹ 黄建玲² 尹璐瑶¹

(¹北京工业大学城市建设学部, 北京 100124)

(²北京市智慧交通发展中心, 北京 100073)

摘要: 为探究电动自行车超速行为影响作用机制,基于共享电动自行车 GPS 轨迹数据,对超速行为进行精准辨识和风险等级划分.考虑土地利用、道路、交通等风险要素,在构建基于机器学习算法的路段超速风险识别模型基础上,通过部分依赖图解析各因素对路段超速风险的影响规律.结果表明:相较于随机森林, CatBoost 对于路段超速风险的识别效果更好;随着土地利用密度、路侧停车密度的降低,公交线路密度、道路等级、人行道宽度、非机动车道宽度的增加,超速风险增加;同时,单向路、非物理隔离的人行道与非机动车道、平峰时段存在较大的路段超速风险.该研究为电动自行车风险骑行行为辨识及影响因素分析提供了一种新的方法,并为非机动车交通安全管理提供了有效的技术支持.

关键词: 电动自行车; 路段超速风险; 轨迹数据; 机器学习; 影响因素分析

中图分类号: U491.1 **文献标志码:** A **文章编号:** 1001-0505(2024)01-0214-10

Analysis of influencing factors of speeding risk on road segments for shared electric bikes

Zhang Xiaolong¹ Bian Yang¹ Zhao Xiaohua¹ Huang Jianling² Yin Luyao¹

(¹ Faculty of Architecture, Civil and Transportation Engineering, Beijing University of Technology, Beijing 100124, China)

(² Beijing Intelligent Transportation Development Center, Beijing 100073, China)

Abstract: In order to explore the mechanism of influencing factors of the electric bike (e-bike) speeding behavior, the global positioning system (GPS) trajectory data of shared e-bikes is used to realize identification and risk classification of speeding behavior. Considering characteristics such as land use, roads, and traffic status, a model that identifies speeding risk on road segments for shared e-bikes is created based on machine learning algorithms. Then, a partial dependency plot is employed to analyze the influence of each influencing factor on speeding risk on road segments. The results show that the CatBoost is better for speeding risk identification on road segments than the random forest model. As land use density and curb parking density decrease and bus line density, road level, sidewalk width, and non-motorized lane width increase, the speeding risk on road segments for shared e-bikes increases. In addition, one-way roads, non-physically separated sidewalks, non-physically separated non-motorized lanes, and non-peak hours are positively associated with speeding risk on road segments. This study provides a novel method for identifying and analyzing risky e-bike behavior and technical support for non-motorized traffic safety management.

Key words: electric bike; speeding risk on road segments; trajectory data; machine learning; influence factor analysis

近年来,电动自行车以其方便快捷、成本低等优点,成为较短距离内居民出行首选交通工具^[1]. 截至 2022 年,我国电动自行车社会保有量超过 3.5 × 10⁸ 辆^[2]. 然而,近 5 年电动自行车交通事故数

收稿日期: 2023-02-12. 作者简介: 张晓龙(1996—),男,博士生;边扬(联系人),女,博士,副教授,bianyang@bjut.edu.cn.

基金项目: 国家自然科学基金资助项目(52072012).

引用本文: 张晓龙,边扬,赵晓华,等.共享电动自行车路段超速风险影响因素分析[J].东南大学学报(自然科学版),2024,54(1):214-223. DOI: 10.3969/j.issn.1001-0505.2024.01.027.

年均增长17.2%,增长速度在所有城市交通方式中居首位^[3]。我国电动自行车交通安全形势依然严峻,提高电动自行车安全水平、减少交通事故刻不容缓。

超速行为已被证明是一种与电动自行车交通事故相关的典型风险骑行行为^[4]。针对电动自行车超速问题,国内外学者主要借助主观问卷调查、实地调研等方式获取超速行为数据,运用统计分析方法,开展超速行为影响因素分析。Ma等^[5]基于问卷调查构建基于多项Logit的超速行为影响因素度量模型。杨雪莹等^[6]利用问卷调查,基于计划行为理论扩展原型意愿模型,构建超速行为心理因素识别模型。Xu等^[7]通过实地视频录像采集超速行为数据,构建基于混合Logit的超速行为影响因素分析模型,结果表明非机动车道宽度、非机动车流量对超速行为有显著影响。然而,现有研究难以摆脱小样本数据的局限性,同时传统统计分析方法在预测性能、复杂非线性关系解析方面存在不足,导致在超速行为影响因素特征表达层面具有一定的片面性和不完整性,难以全面、准确、精细地刻画超速行为影响机制。

互联网租赁自行车和人工智能算法的快速发展,为电动自行车交通安全研究提供了可能。首先,截止2021年,中国共享电动自行车投放规模已达 3.82×10^6 辆^[8],其搭载的GPS等设备可实现轨迹定位信息的精准感知汇聚,为研究风险骑行行为提供了新途径。其次,在交通安全风险影响因素分析方面,相较于传统统计模型,机器学习算法拥有更强大的非线性映射、自学习和容错能力^[9]。同时,机器学习算法的可解释性对于整个模型的理解至关重要,目前国内外已有研究开始应用部分依赖图技术,实现特征变量对预测结果的影响机制解析^[10]。

综上所述,本文以共享电动自行车骑行大数据为基础,解决基于GPS轨迹数据的数据预处理与超速行为精准辨识问题,构建基于机器学习算法的路段超速风险识别模型,并通过部分依赖图解析各因素对超速行为的复杂影响。本研究为解决电动自行车交通系统安全问题提供了新的方法,并为主动安全防控和治理提供了理论支持。

1 数据

1.1 数据来源

1.1.1 共享电动自行车轨迹数据

在共享电动自行车骑行中,移动应用程序软件

通过车身GPS设备采集该车辆的运行状态信息,包括订单信息、开关锁信息及轨迹链信息等。

本文使用的轨迹数据来源于中国某品牌共享电动自行车服务商提供的用户轨迹订单数据,时间为2020-05和2020-07。该品牌共享电动自行车在湖南省长沙市的平均日骑行量约为 2.65×10^4 次,产生约 2.5×10^7 个轨迹点。图1为基于共享电动自行车轨迹点绘制的热力图,根据轨迹点的空间分布,芙蓉区是轨迹点集中分布的区域之一。




图1 长沙市轨迹点热力图($r=500\text{ m}$)

1.1.2 路网数据

目标路网位于长沙市芙蓉区,地理信息数据可通过开源地图平台OSM(OpenStreet map)获取,包括道路ID、道路等级、路段长度、单双向标识等。芙蓉区路网拓扑结构如图2所示。本文选择芙蓉区是因为其位于长沙市中心,其辖内共享电动自行车每天的骑行量较大($195\text{ 辆}/(\text{d} \cdot \text{km}^2)$),长沙市各区排名1),同时道路交通特征及土地利用特征多样,可为路段超速风险影响因素分析提供丰富的数据基础,有利于提高研究准确性。



图2 芙蓉区路网

1.1.3 土地利用特征数据

土地利用特征数据来源于高德地图API中的兴趣点(POI)数据,选择公司企业、金融保险服务、科教文化服务、医疗保健服务、政府机构及社会团体、商务住宅、餐饮服务、购物服务、风景名胜、生活服务、体育休闲服务、住宿服务共12个与共享电动自行车出行相关的POI特征类别。本文采用路段邻近匹配方法,利用路段周围50m的缓冲区范围

<http://journal.seu.edu.cn>

实现各类土地利用 POI 的路段聚合^[1]。

1.1.4 道路交通特征数据

道路特征数据除道路等级、路段长度等可由 OSM 获取外,其余数据通过百度街景地图获取,包括非机动车道隔离形式、非机动车道宽度、人行道隔离形式、人行道宽度等。交通特征数据包括路侧停车数和公交线路数,其中路侧停车数通过百度街景地图获取,公交线路数通过高德地图 API 获取。本文借助路段临近匹配方法,利用路段周围 20 m 的缓冲区范围实现公交线路数的路段聚合^[2]。

1.2 超速行为判定

1.2.1 数据清洗

研究区域范围内共享电动自行车的原始订单数量为 371 995 条,删除骑行人性别和年龄不详、车辆开关锁经纬度缺失、无轨迹信息等信息缺失的订单记录,共获得 324 555 条订单,有效订单数占 87.247%。将订单记录切分为独立轨迹点便于后续数据处理,其中每个轨迹点信息包括订单 ID、性别、年龄、时间戳、经度、纬度、起讫点标识。由于自身 GPS 传感器设备故障或城市高楼建筑物遮挡等因素的影响,共享电动自行车在运行过程中的轨迹点会出现数据异常,表现为过大地偏离真实位置(漂移点,见图 3(a))或丢失(缺失点,见图 3(b)),导致轨迹点无法有效映射位置信息。本文通过对比距离、时间及速度特征,发现基于时间、速度

的数据异常检查方法能够实现轨迹数据全样本的异常标定,故设计基于箱线图分析的以时间、速度上限为异常检查标准的异常数据清洗算法。具体步骤如下:

①将轨迹链中 n 个轨迹点按时间升序排序,定义当前轨迹点与上一个轨迹点分别为 P_i 、 P_{i-1} 。

②对于漂移点,当 $d_{i-1,i} > vt_{i-1,i}$ 时,删除轨迹点 P_i 。其中, $d_{i-1,i}$ 为 P_{i-1} 与 P_i 轨迹点间的球面距离; v 为容许速度上限值,本文中 v 取 40 km/h; $t_{i-1,i}$ 为通过 P_{i-1} 与 P_i 两轨迹点的时间。

③对于缺失点,当 $t_{i-1,i} > 20$ s 时,将原轨迹链截断,生成新的轨迹子链。

④对于轨迹子链,当轨迹点个数连续超过 5 个时,将其作为轨迹子链保留。

经过轨迹数据清洗,共获得 172 294 条轨迹链(多条轨迹子链视为 1 条轨迹链),有效轨迹链占 53.086%。

1.2.2 地图匹配


地图匹配用于将轨迹点投影到给定数字地图的相应路段上,使轨迹点在地图匹配后无需借助数字地图即可获得其所在位置的道路信息。本文借助 Yuan 等^[3]开发的基于交互式投票的地图匹配(IVMM)算法,该算法考虑了 GPS 轨迹的时空网络拓扑信息,并设计了一种基于交互式投票的策略来模拟轨迹点之间的加权相互影响,以解决复杂路网下由于轨迹数据漂移带来的邻近道路错误匹配问题,性能优异。IVMM 算法考虑了机动车交通运行特征,而电动自行车相比机动车更为灵活,例如电动自行车会经常存在逆行等行为。本文基于共享电动自行车轨迹特征,对 IVMM 算法进行改进及参数标定。具体地图匹配过程如下:

①索引。按照时间序列升序排列轨迹子链及子链中的轨迹点。

②匹配。对算法进行了一些改进:删除高速公路、快速路等电动自行车不能通行的道路;考虑电动自行车逆行行为多发,逆行超速尤为危险,因此将道路拓扑关系由有向图改为无向图,避免逆行轨迹链无法匹配或错误匹配至对向车道等情况,保证逆行行为轨迹链正确匹配;增加偏移量字段(即轨迹点 P_i 与路段 R_k 道路中心线的投影距离 O_{ik}),用以提取道路红线范围内的轨迹链。参数标定结果如下:最大候选路段数 $\alpha = 5$;邻域查询半径 $r = 150$ m;当 $G_j < 10$ s 时距离加权函数路网参数 $\beta = 50$,当 $G_j \geq 10$ s 时 $\beta = 200$,其中 G_j 为第 j 条轨迹链中相邻 2 个轨迹点的时间间隔集合的众数值。每个轨



(a) 轨迹点漂移



(b) 轨迹点缺失

图 3 数据错误示例

迹点经过地图匹配后会增加 5 个属性,即路段 ID、道路等级、路段长度、单双向标识和偏移量。

③优化. 本文研究目的之一是确定道路特征对超速行为的影响,因此提取道路红线范围内的轨迹链非常必要. 考虑到长沙市不同道路等级的道路红线宽度范围^[4]及 GPS 设备的定位误差,确定了不同道路等级下的偏移量阈值上限,如表 1 所示。

④验证. 为了评估 IVMM 算法的精度,本文采用随机抽样法从 $G_j < 10$ s 及 $G_j \geq 10$ s 的轨迹数据集中各抽取 200 条轨迹链,通过人工观察法确定其真实匹配路段结果,然后利用下式计算 IVMM 算法的正确匹配比例:

$$M_p = \frac{N_c}{N_T} \times 100\% \quad (1)$$

式中, M_p 为正确匹配比例,%; N_c 为 IVMM 算法的正确匹配轨迹点数; N_T 为 200 条轨迹链中的轨迹点总数量. 经计算,IVMM 算法在 $G_j < 10$ s 及 $G_j \geq 10$ s 的抽样轨迹数据集中的正确匹配比例分别达到了 96.698% 和 92.651%,匹配结果良好。

表 1 不同道路等级下偏移量阈值上限 m

道路等级	单向路	双向路
主干路	25	35
次干路	20	30
支路	15	20

经过地图匹配共获得 124 617 条轨迹链,有效轨迹链占比为 72.328%。

1.2.3 共享电动自行车超速行为判定

《中华人民共和国道路交通安全法》中规定电动自行车在非机动车道内行驶时,最高时速不得超过 15 km/h,而在实际骑行中,电动自行车的骑行速度往往超过 15 km/h. 同时,国内外对机动车超速行为的研究中,大多根据各等级道路限速值判定车辆是否超速^[5],而电动自行车在各等级道路中缺乏限速信息,同时国内外尚缺乏对电动自行车超速行为的研究,导致电动自行车超速行为判定的理论依据较少. 在机动车危险驾驶行为的研究中,通常将 85% 分位的行为风险值作为高风险的划分标准^[6]. 对此,本文选取轨迹点数据集中 85% 分位速度作为超速行为的判定标准,结合图 4 中超速行为判定示例,具体判定算法如下:

①将轨迹链中 n 个轨迹点按时间升序排序,定义当前轨迹点与上一个轨迹点分别为 P_i, P_{i-1} .

②计算轨迹点 P_i 的点速度 v_i ,本文选用 P_{i-1} 与 P_i 之间的平均速度 $\bar{v}$ 替代 v_i ,其中 $\bar{v} = d_{i-1,i}/$

$t_{i-1,i}$.

③计算轨迹点数据集中 85% 分位速度 v_{85th} ,本文中 v_{85th} 取值为 20 km/h.


④依次比较轨迹点 P_i 速度 v_i 与 v_{85th} 大小,若 $v_i > v_{85th}$,则轨迹点 P_i 识别为超速点,否则识别为正常骑行点.

⑤从第 1 个超速点开始,若连续超过 1 个轨迹点为超速点^[7],且运行时间超过 10 s,则记为 1 次超速事件。



图 4 超速行为判定示例

经统计,共获得 130 562 次共享电动自行车超速事件,平均每次骑行产生 1.048 次超速事件,超速事件发生较为频繁. 如图 5(a) 所示,共享电动自行车超速事件分布与交通流量的时变特征曲线基本一致,高峰时段超速事件增加,早高峰尤为明显,表明共享电动自行车超速事件与出行需求有较大的相关性. 如图 5(b) 所示,涉及共享电动自行车的超速事件多集中发生在芙蓉区的浏阳河西侧,基本沿主、次干道路分布,同时呈现较为明显的聚集特征,空间影响较为复杂。



(a) 时间分布



(b) 空间分布

图 5 超速事件时空分布特征

<http://journal.seu.edu.cn>

1.3 关键参数提取

1.3.1 土地利用与交通特征指数

在原始数据中,部分变量可直接用于电动自行车超速行为影响因素解析,例如道路等级、非机动车道宽度等. 其他变量需要在原始数据的基础上提取新的特征变量,如土地利用密度、路侧停车密度、公交线路密度,其具体计算公式如下:

$$D_{u,k} = \frac{N_{u,k}}{L_k} \quad (2)$$

$$D_{p,k} = \frac{N_{p,k}}{L_k} \quad (3)$$

$$D_{b,k} = \frac{N_{b,k}}{L_k} \quad (4)$$

式中, L_k 为第 k 个路段的长度,km; $D_{u,k}$ 为第 k 个路段的土地利用密度,个/km; $N_{u,k}$ 为第 k 个路段的各类 POI 数量之和; $D_{p,k}$ 为第 k 个路段的路侧停车密度,辆/km; $N_{p,k}$ 为第 k 个路段的路侧停车数量之和,辆; $D_{b,k}$ 为第 k 个路段的公交线路密度,路/km; $N_{b,k}$ 为第 k 个路段的公交线路数量之和,路.

1.3.2 路段超速风险等级

由于不同路段长度和某时段内共享电动自行车骑行者数量的差异,原始数据无法在同一尺度下衡量路段超速行为风险程度. 故需要将原始超速事件发生频次转化为集计超速事件发生频次后再开

展分析. 集计超速事件频次反映了单位时间内单位车辆、单位长度路段上的超速事件频次,计算公式如下:

$$F_{a,k}^t = \frac{F_{s,k}^t}{B_k^t L_k} \quad (5)$$

式中, $F_{a,k}^t$ 为第 k 个路段上、第 t 个小时内的集计超速事件频次,次/(辆 · km); $F_{s,k}^t$ 为第 k 个路段上、第 t 个小时内发生的超速事件频次,次/h; B_k^t 为第 k 个路段上、第 t 个小时内的共享电动自行车车辆数,辆/h.

为了表征超速行为在不同因素影响下的差异性,本文采用 K-means 聚类将路段超速行为离散化为 2 个风险等级,并以聚类后各类别的最大值、最小值设定区间划分阈值. 低超速风险道路定义为超速行为发生较少、风险较低的道路, $F_{a,k}^t \in [0, 0.462)$; 高超速风险道路定义为超速行为发生较多、风险较高的道路, $F_{a,k}^t \in [0.462, +\infty)$.

1.4 数据库构建

筛选出行订单量大于 0 且长度大于 10 m 的路段,共获得 2 224 个路段样本,以路段单元(路段 ID) 及时间段(平/高峰) 为基础搭建时空网格,匹配所有特征数据(超速行为、道路特征、交通特征等),共获得 4 266 条数据记录,以此构建电动自行车超速行为影响特征数据库. 数据库中各变量的统计性描述如表 2 和表 3 所示.

表 2 分类变量的定义与统计

特征类别	特征名称	特征水平	特征数量	占比/%
超速行为	路段超速风险等级	低	2 627	61.580
		高	1 639	38.420
时间特征	平/高峰	平峰	2 169	50.844
		高峰	2 097	49.156
道路特征	道路方向	双向路	1 657	38.842
		单向路	2 609	61.158
	道路等级	支路	2 160	50.633
		次干路	872	20.441
		主干路	1 234	28.926
	自行车道宽度	无	2 738	64.182
		窄	641	15.026
		宽	887	20.792
	非机动车道隔离形式	无隔离	2 738	64.182
		非物理隔离(标线隔离)	1 272	29.817
		物理隔离(护栏/绿化隔离)	256	6.001
道路特征	人行道宽度	无	938	21.988
		窄	1 368	32.068
		宽	1 960	45.945
	人行道隔离形式	无隔离	938	21.988
		非物理隔离(路缘石隔离)	2 786	65.307
		物理隔离(护栏/绿化隔离)	542	12.705

表 3 连续变量的定义与统计

特征类别	特征名称	平均值	标准差	最大值	最小值
交通特征	路侧停车密度/(辆 · km ⁻¹)	48. 676	82. 521	679. 440	0
	公交线路密度/(路 · km ⁻¹)	3. 180	14. 654	251. 324	0
土地利用特征	土地利用密度/(个 · km ⁻¹)	494. 070	602. 802	5745. 806	0

2 路段超速风险影响因素分析

2.1 电动自行车路段超速风险识别模型

本文选用 CatBoost 构建电动自行车路段超速风险识别模型. CatBoost 是梯度提升算法中的一种,是继 XGBoost、LightGBM 之后第 3 个基于 GB-DT 改进的算法. CatBoost 有以下独特优势: ①分类类型特征处理,在训练模型之前可以不用手动处理分类类型特征变量; ②鲁棒性强,减少了对超参数调优的需求,并降低了过拟合,更具有通用性. 算法过程如下:

①输入 m 个样本 $\{ (x_l, y_l) \}_{l=1}^m$ 、 I 棵决策树,以及数列 $[1, m]$ 的随机排列 σ .

②在第 q ($q = 1, 2, \dots, I$) 棵决策树中,分别对每个样本 x_l ($l = 1, 2, \dots, m$) 训练一个不包含 x_l 的模型 M_l ,计算模型 M_l 关于样本 x_l 的残差 $r_l = y_l - M_{\sigma(l)-1}(x_l)$,并使用该残差来训练基学习器 $\Delta M = \text{LearnModel}((x_w, r_w) : \sigma(w) \leq l), w = 1, 2, \dots, m$; 然后,更新模型 $M_l = M_l + \Delta M$.

③对 I 棵决策树进行训练,输出最终模型 M_m .

2.2 模型评价指标

本文以机器学习模型中常用的分类评价指标准确率、召回率、精确率和 F_1 值作为模型评价指标,并选取混淆矩阵可视化模型识别结果.

2.3 部分依赖图

部分依赖图(PDP)是一种机器学习预测结果的可解释方法,在控制其他解释变量不变的情况下改变当前解释变量的值,揭示解释变量与响应变量预测值的边际效应(线性、单调或非线性)^[18]. 本文基于 PDP 解析土地利用特征、道路特征、交通特征等因素对路段超速风险的复杂影响. PDP 的计算公式如下:

$$\hat{f}_s(x_s) = \int \hat{f}(x_s, x_c) dP(x_c) \quad (10)$$

式中, x_s 为某一元素成分特征变量; $\hat{f}_s(x_s)$ 表示在 x_s 的每个取值下对应标签的估计值; x_c 为模型中除 x_s 外其他的特征变量; $\hat{f}(x_s, x_c)$ 为 x_s 与 x_c 的联合概率密度; $P(x_c)$ 为 x_c 的边缘密度函数,

$$P(x_c) = \int p(x) dx_s \quad (11)$$

其中, $p(x)$ 为模型中所有特征变量的联合概率密度.

通过计算训练数据中的平均值来估计部分依赖函数 $\hat{f}_s$, 也称为蒙特卡洛方法. 表达式如下:

$$\hat{f}_s(x_s) = \frac{1}{m} \sum_{l=1}^m \hat{f}(x_s, x_c^l) \quad (12)$$

式中, x_c^l 为数据集中除 x_s 外其他特征变量的实际特征值.

特别地,对于分类特征,可通过强制使所有数据实例具有相同的特征类别来获得 PDP 估计.

3 模型构建与结果分析

3.1 模型构建与性能评价

考虑到路段超速风险等级为分类特征且数据库中分类变量与连续变量异构的特点,本文选用 CatBoost,并选择随机森林(RF)作为对比模型. 考虑时间特征、道路特征、交通特征、土地利用特征方面的多类型特征变量,构建路段超速风险识别模型. 基于随机分布原则,按 9:1 比例将数据集划分为训练集与测试集,训练集用于训练识别模型,测试集用于评估模型的性能. 训练模型时,采用五折交叉验证方法将训练集数据随机分为 5 份,每次训练会以 4 个子样本训练和 1 个子样本验证的形式进行; 基于网格搜索方式进行参数调优,实现指定参数值的穷举搜索. CatBoost 与 RF 的优化参数如表 4 所示.

表 4 CatBoost 与 RF 的优化参数

模型	参数	搜索值	最优值
CatBoost	iterations	1 000, 2 000, ..., 10 000	6 000
	depth	5, 6, ..., 10	6
	learning_rate	0.01, 0.02, ..., 0.10	0.1
	subsample	0.60, 0.65, ..., 0.95	0.75
	l2_leaf_reg	6, 7, ..., 15	8
	n_estimators	1 000, 2 000, ..., 10 000	7 000
RF	max_depth	5, 10, ..., 30	10
	min_samples_spilt	2, 4, ..., 10	4
	min_samples_leaf	1, 3, ..., 9	1
	bootstrap	True, False	False
	criterion	gini, entropy	gini

模型参数调优后计算模型性能评价指标,结果如表 5 所示. 可看出,基于 CatBoost 的电动自行车路段超速风险识别模型具有精准识别的能力.

<http://journal.seu.edu.cn>

表5 CatBoost 与 RF 性能对比 %

模型	准确率	召回率	精确率	F_1 值
CatBoost	86.885	86.585	80.682	83.529
RF	81.030	81.098	72.678	76.657

3.2 特征重要性分析

特征重要性是一个衡量每个输入特征对模型预测结果影响程度的指标,特征重要性越高,即该特征对路段超速风险等级的识别结果影响越大.如图6所示,特征重要性由大到小依次为土地利用密度、路侧停车密度、道路等级、人行道宽度、非机动车道宽度、平/高峰、公交线路密度、人行道隔离形式、道路方向、非机动车道隔离形式.




图6 CatBoost 特征重要性排序

3.3 影响因素解析

本文利用 PDP 解析土地利用特征、交通特征、道路特征、时间特征等相关因素对路段超速风险的复杂影响规律.

3.3.1 土地利用特征相关变量

在土地利用特征相关变量中,土地利用密度是影响共享电动自行车路段超速风险的最主要特征.

由图7可知,土地利用密度与 $\hat{f}_s$ 呈非线性负相关关系,即随着土地利用密度的增长, $\hat{f}_s$ 下降,但下降幅度逐渐减弱. Kuzmyak^[9] 的研究表明,更高密度的土地开发加剧了相邻街道和道路的交通拥堵. Zhang 等^[2] 研究也发现,土地利用密度与交通拥堵之间存在较高的正相关性,即土地利用密度越高,交通出行量越大,交通拥堵越严重,共享电动自行车骑行者骑行速度越低,导致路段超速风险降低.





图7 土地利用特征部分依赖图


3.3.2 交通特征相关变量

在交通特征相关变量中,路侧停车密度对路段超速风险等级的影响较大,公交线路密度的影响较小.

由图8(a)可见,路侧停车密度与 $\hat{f}_s$ 呈线性负相关关系,即随着路侧停车密度增加,共享电动自行车路段超速风险降低. 共享电动自行车骑行者在通过有路侧停车的路段时,不仅受到停靠在路侧的机动车的静态影响,而且还受到机动车驶入或驶离过程中作为动态障碍物产生的动态影响^[21]. 首先,路侧停车占用道路面积,使道路有效宽度减小,导致道路通行能力减小,引起交通拥挤,骑行速度被迫降低^[22];其次,骑行过程中骑行者心理上容易产生恐惧感,安全系数降低,骑行速度降低^[23]. 然后,骑行者骑行过程中常遇到机动车正在驶入、驶离路侧停车位以及开门等行为的干扰,为避免与其发生冲突而被迫减速^[24]. 综上,当通过有路侧停车的路



(a) 路侧停车密度



(b) 公交线路密度

图8 交通特征部分依赖图

段时,共享电动自行车骑行者会受到交通拥挤、恐惧心理、机动车停车行为等多方面因素的影响导致其减速。但与此同时,由于机动车路侧停车导致的电动自行车交通事故伤害依然不容忽视。

由图 8(b) 可见,公交线路密度与 $\hat{f}_s$ 呈非线性正相关关系,即随着公交线路密度的增加,路段超速风险增加,但风险增加幅度逐渐减弱。经调研发现,研究区域芙蓉区内公交站 85.813% 为直线式停靠站,且 66.782% 的停靠区域位于非机动车道上,电动自行车与公交车交通冲突较为严重。Zhao 等^[25] 研究发现,公交车驶入与驶离公交车站时对非机动车骑行者的速度有显著影响,大多数骑行者不会在公交车后等待,而是选择从公交车侧边或以越线行驶方式加速通过公交车站。综上,随着公交线路密度增加,公交车与共享电动自行车的交通冲突加剧,导致骑行者超越行为意愿加强,进而选择冒险骑行,加速穿越^[24],路段超速风险增加。

3.3.3 道路特征相关变量

在道路特征相关变量中,道路等级、人行道宽度和非机动车道宽度对路段超速风险等级的识别结果影响较大,道路方向、人行道隔离形式、非机动车道隔离形式的影响较小。

由图 9(a) 可见,支路、次干路、主干路条件下的 $\hat{f}_s$ 分别为 0.295、0.446、0.528,即道路基础条件越好,共享电动自行车骑行者越容易超速,导致路段超速风险增加。

由图 9(b) 可见,无人行道、窄人行道、宽人行道条件下的 $\hat{f}_s$ 分别为 0.333、0.357、0.403。由图 9

(c) 可见,无非机动车道、窄非机动车道、宽非机动车道条件下的 $\hat{f}_s$ 分别为 0.367、0.441、0.459。人行道或非机动车道越宽,共享电动自行车骑行速度越高,进而导致路段超速风险增加。其中,人行道越宽,行人对非机动车道通行空间的侵入减少,导致人非交通干扰降低,共享电动自行车骑行更加通畅;非机动车道越宽,共享电动自行车的侧向干扰与摩擦越弱,共享电动自行车能够随意超越同车道非机动车,使得骑行速度更快,进而导致路段超速风险增加^[27-28]。

由图 9(d) 可见,人行道隔离形式的 $\hat{f}_s$ 由大到小依次为: 非物理隔离(0.389)、物理隔离(0.372)、无隔离(0.363)。由图 9(e) 可见,非机动车道隔离形式的 $\hat{f}_s$ 由大到小依次为: 非物理隔离(0.408)、物理隔离(0.386)、无隔离(0.380)。可见,道路隔离形式对路段超速风险产生了非线性影响。与其他文献研究结果类似,针对无隔离路段,于姗姗^[29] 指出非机动车在人非混行无隔离路段,非机动车受路段行人交通影响,速度较纯非机动车交通流相比降低;王丹^[27] 指出机非混行导致电动自行车与机动车交通干扰严重,骑行者无法随意提高其行驶速度且更加谨慎。然而,针对物理隔离与非物理隔离路段,前期研究发现,物理隔离路段的电动自行车骑行速度较非物理隔离路段高,因为非物理隔离路段交通干扰较为严重,骑行者骑行压力较大,安全感降低,导致速度整体低于物理隔离路段^[30]。但本文研究结果表明,非物理隔离路段的共




图9 道路特征部分依赖图

享电动自行车路段超速风险高于物理隔离路段,其原因可能在于,虽然标线隔离、路缘石隔离分隔了机非、人非同向交通流,但共享电动自行车仍然受到了同向交通干扰,同时共享电动自行车骑行者中年轻群体居多^[31],年轻骑行者骑行行为更冒险、激进,倾向通过提速以摆脱当前交通干扰状况,进而导致路段超速风险增加。

由图9(f)可见,在道路方向方面,单向路上 $\hat{f}_s$ 为0.492,高于双向路 $\hat{f}_s$ 的0.395。一般情况下,单向路道路条件较好,共享电动自行车骑行者容易超速,导致路段超速风险增加。

3.3.4 时间特征相关变量

图10表明,在平峰时段 $\hat{f}_s$ 为0.413,高于高峰时段的 $\hat{f}_s$ (0.358),即平峰时段的交通出行量较小,交通较为通畅,共享电动自行车骑行者可以较为自由地选择骑行速度,导致路段超速风险增加。




图10 时间特征部分依赖图

本文对比了 CatBoost 与传统二元 Logit 在关键特征变量识别、边际效应解析方面的异同。结果表明,两者具有较高一致性。此外,CatBoost 能够更准确地识别路段超速风险,并结合部分依赖图更好地解析特征变量的非线性影响机制。但由于机器学习模型、传统统计模型在算法上的差异性,关键特征变量的重要性排序会存在不同。因此,在实际工程应用中,对于特征空间较大、分类型自变量较多、存在非线性影响关系的情况^[32-33],建议优先考虑采用 CatBoost。

4 结论

1) 本文基于共享电动自行车 GPS 轨迹数据,实现了超速行为精准辨识、风险等级划分。借助 CatBoost 构建路段超速风险识别模型,通过部分依赖图解析土地利用、道路交通等风险要素对路段超速风险的影响规律。

2) 结果表明,随着土地利用密度、路侧停车密度的降低,公交线路密度、道路等级、人行道宽度、非机动车道宽度的增加,超速风险增加;同时,单向

路、非物理隔离的人行道与非机动车道、平峰时段存在大的路段超速风险。

3) 本文为解决电动自行车交通系统安全问题提供了新的方法,为主动安全防控和靶向治理方案提供了理论支持。未来将开展多因素耦合交互作用下的路段超速风险影响因素分析,进一步探究电动自行车路段超速风险的影响机制。

参考文献 (References)

- 王涛. 电动自行车风险驾驶行为及事故机理研究[D]. 南京: 东南大学, 2017.
Wang T. The mechanism study on the risky driving behavior and accident of electric bike riders [D]. Nanjing: Southeast University, 2017. (in Chinese)
- 吴智联. 我国电动自行车的社会保有量已达 3.5 亿辆: 电动自行车产业发展趋势现状分析 [EB/OL]. (2022-12-09) [2023-02-01]. <https://www.chinairn.com/hyxx/20221209/17570872.shtml>.
- 于昊, 赵琳娜, 戴帅. 城市电动自行车交通安全发展趋势及应对策略 [J]. 城市交通, 2022, 20(1): 76-82. DOI: 10.13813/j.cn11-5141/u.2021.0052.
Yu H, Zhao L N, Dai S. Traffic safety of electric bicycles in cities: Development trends and strategies [J]. Urban Transport of China, 2022, 20(1): 76-82. DOI: 10.13813/j.cn11-5141/u.2021.0052. (in Chinese)
- Wang C, Kou S Y, Song Y C. Identify risk pattern of E-bike riders in China based on machine learning framework [J]. Entropy, 2019, 21(11): e21111084. DOI: 10.3390/e21111084. DOI: 10.3390/e21111084.
- Ma C X, Zhou J B, Yang D, et al. Research on the relationship between the individual characteristics of electric bike riders and illegal speeding behavior: A questionnaire-based study [J]. Sustainability, 2020, 12(3): 799. DOI: 10.3390/su12030799.
- 杨雪莹, 张雨婷, 王华容, 等. 电动自行车超速骑行行为的心理因素预测 [J]. 交通医学, 2022, 36(4): 356-360. DOI: 10.19767/j.cnki.32-4412.2022.04.007.
Yang X Y, Zhang Y T, Wang H R, et al. Prediction of psychological factors of overspeed riding behavior of electric bicycle [J]. Medical Journal of Communications, 2022, 36(4): 356-360. DOI: 10.19767/j.cnki.32-4412.2022.04.007. (in Chinese)
- Xu C, Guo H F, Xu L, et al. Speeding behavior and speed limits for heterogeneous bicycle flow [J]. Traffic Injury Prevention, 2019, 20(7): 759-763. DOI: 10.1080/15389588.2019.1642471.
- 赫蒂. 共享单车行业数据分析: 预计 2022 年中国共享电单车投放规模为 495 万辆 [EB/OL]. (2022-07-27) [2023-02-01]. <https://www.iimedia.cn/c1061/87219.html>.
- 赵晓华, 杨海益, 姚莹, 等. 高速公路桥梁路段交通安全风险评价及影响要素挖掘 [J]. 同济大学学报(自然科学版), 2022, 50(11): 1637-1646. DOI: 10.11908/j.issn.0253-374x.21511.
Zhao X H, Yang H Y, Yao Y, et al. Traffic safety evaluation and feature analysis of freeway bridge sections [J]. Journal of Tongji University (Natural Science),

- 2022, 50(11): 1637 – 1646. DOI: 10.11908/j.issn.0253-374x.21511. (in Chinese)
- [10] Kidando E, Kitali A E, Kutela B, et al. Prediction of vehicle occupants injury at signalized intersections using real-time traffic and signal data [J]. *Accident Analysis & Prevention*, 2021, 149: 105869. DOI: 10.1016/j.aap.2020.105869.
- [11] 边扬, 杨家夏, 赵晓华, 等. 基于轨迹数据的共享电动自行车逆行风险行为影响因素研究 [J]. *中国公路学报*, 2021, 34(12): 262 – 275. DOI: 10.19721/j.cnki.1001-7372.2021.12.020.
- Bian Y, Yang J X, Zhao X H, et al. Research on influencing factors of reverse riding risk behavior of shared E-bike based on trajectory data [J]. *China Journal of Highway and Transport*, 2021, 34(12): 262 – 275. DOI: 10.19721/j.cnki.1001-7372.2021.12.020. (in Chinese)
- [12] Luan S, Li M, Li X, et al. Effects of built environment on bicycle wrong way riding behavior: A data-driven approach [J]. *Accident Analysis & Prevention*, 2020, 144: 105613. DOI: 10.1016/j.aap.2020.105613.
- [13] Yuan J, Zheng Y, Zhang C Y, et al. An interactive-voting based map matching algorithm [C] // *2010 Eleventh International Conference on Mobile Data Management*. Kansas City, MO, USA, 2010: 43 – 52. DOI: 10.1109/MDM.2010.14.
- [14] 刘新武. 长沙市城市道路红线分析与研究 [C] // *规划引领下的新型城市化研究——2009年湖南省优秀城乡规划论文集*. 长沙, 2009: 263 – 269.
- [15] Liu H Y, Fu C Y, Jiang C Z, et al. Bayesian hierarchical spatial count modeling of taxi speeding events based on GPS trajectory data [J]. *PLoS One*, 2020, 15(11): e0241860. DOI: 10.1371/journal.pone.0241860.
- [16] Seo H, Shin J, Kim K H, et al. Driving risk assessment using non-negative matrix factorization with driving behavior records [J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(11): 20398 – 20412. DOI: 10.1109/TITS.2022.3193125.
- [17] 付川云, 刘海玥, 胥川, 等. 一种基于连续超速 GPS 轨迹点的超速事件实时探测方法: CN108417050A [J]. 2018-08-17.
- [18] Friedman J H. Greedy function approximation: A gradient boosting machine [J]. *The Annals of Statistics*, 2001, 29(5): 1189 – 1232. DOI: 10.1214/aos/1013203451.
- [19] Kuzmyak J R. Land use and traffic congestion [R]. Phoenix, Arizona, USA: Department of Transportation Research Center, 2012.
- [20] Zhang T Q, Sun L S, Yao L Y, et al. Impact analysis of land use on traffic congestion using real-time traffic and POI [J]. *Journal of Advanced Transportation*, 2017, 2017: 1 – 8. DOI: 10.1155/2017/7164790.
- [21] 刘志士. 路侧停车对非机动车骑行干扰机理研究 [D]. 哈尔滨: 哈尔滨工业大学, 2016.
- Liu Z S. Study on interference mechanism for curb parking to riding of non-motor vehicles [D]. Harbin: Harbin Institute of Technology, 2016. (in Chinese)
- [22] 邹贞元, 徐亚国, 安实. 城市静态交通管理理论与应用 [M]. 广州: 广州出版社, 2000: 113 – 118.
- [23] 李萌. 公交站点区域非机动车骑行特性及影响因素研究 [D]. 西安: 长安大学, 2018.
- Li M. Characteristics and influencing factors of non-motorized riding on public transport stations [D]. Xi'an: Chang'an University, 2018. (in Chinese)
- [24] 叶晓飞, 陈峻, 冯树民, 等. 路内停车影响下非机动车流速度模型 [J]. *哈尔滨工业大学学报*, 2016, 48(3): 115 – 119. DOI: 10.11918/j.issn.0367-6234.2016.03.019.
- Ye X F, Chen J, Feng S M, et al. Model of non-motorized vehicle flow speed influenced by curbside parking [J]. *Journal of Harbin Institute of Technology*, 2016, 48(3): 115 – 119. DOI: 10.11918/j.issn.0367-6234.2016.03.019. (in Chinese)
- [25] Zhao D, Wang W, Zheng Y A, et al. Evaluation of interactions between buses and bicycles at stops [J]. *Transportation Research Record: Journal of the Transportation Research Board*, 2014, 2468(1): 11 – 18. DOI: 10.3141/2468-02.
- [26] 董一璠. 直线式公交车站区域非机动车运行安全性分析 [D]. 西安: 长安大学, 2021.
- Dong Y F. Safety analysis of non-motorized vehicles when passing through the curbside bus stop district [D]. Xi'an: Chang'an University, 2021. (in Chinese)
- [27] 王丹. 路段非机动车交通流特性研究 [D]. 西安: 长安大学, 2014.
- Wang D. Research on characteristics of non-motor vehicle traffic flow on road section [D]. Xi'an: Chang'an University, 2014. (in Chinese)
- [28] 徐程. 路段混合自行车交通运行特性与风险评估 [D]. 长春: 吉林大学, 2016.
- Xu C. Operation characteristics and risk evaluation for mixed bicycle traffic flow on bicycle path [D]. Changchun: Jilin University, 2016. (in Chinese)
- [29] 于姗姗. 城市行人—非机动车共享路段交通运行特性及分隔设施设置应用研究 [D]. 南京: 东南大学, 2015.
- Yu S S. The research on operational characteristics and isolation facilities application of shared-use paths [D]. Nanjing: Southeast University, 2015. (in Chinese)
- [30] 刘洋. 非物理隔离机非车道交通运行安全与效率研究 [D]. 西安: 长安大学, 2016.
- Liu Y. The research on safety and efficiency of non-barrier section operation in urban road [D]. Xi'an: Chang'an University, 2016. (in Chinese)
- [31] Zhang X L, Huang J L, Bian Y, et al. Shared e-bike riders' psychology contribution to self-reported traffic accidents: A structural equation model approach with mediation analysis [J]. *Journal of Transportation Safety & Security*, 2023, 15(9): 895 – 917. DOI: 10.1080/19439962.2022.2137868.
- [32] Vardhan M, Banerjee K, Aggarwal D. A systematic approach for the detection of software bug using catboost [C] // *2022 International Conference on Machine Learning, Big Data, Cloud and Parallel Computing (COM-IT-CON)*. Faridabad, India, 2022: 414 – 419. DOI: 10.1109/COM-IT-CON54601.2022.9850519.
- [33] Nasir N, Kansal A, Alshaltone O, et al. Water quality classification using machine learning algorithms [J]. *Journal of Water Process Engineering*, 2022, 48: 102920. DOI: 10.1016/j.jppe.2022.102920.